

## ממ"ן 11 – מבוא לראייה ממוחשבת, נדב מידן ת.ז. 200990240


### שאלה 1

(א)


במטריצה מגודל  $50 \times 50$  ישנן 2500 דגימות, לכן השתמשתי בפונקציית `random.normal` עם הפרמטרים הגאוסיים (ההתפלגות הממוצעת וסטיית התקן) הנתונים בשאלה, על פני 2500 דגימות.

ע"מ להציג את המטריצה, השתמשתי בספרייה `matplotlib`, ובמתודה `gray` ע"מ להציג ברמות אפור.

Out[23]: <matplotlib.image.AxesImage at 0x1818d515280>




(ב) אפשר לראות את הגאוסיאן באדום (יצרתי אותו בעזרת פונקציה מובנית מהאינטרנט) ואת ההתפלגות עם נתוני הממוצע וסטיית התקן שלנו בשאלה, ואנחנו רואים שההתפלגות הנורמלית מצליחה להתחקות די טוב אחרי הגאוסיאן אך לא בדיוק עליו.



ג) קריאת התמונה 'kids' נעשית ע"י מתודת imshow של cv2 וע"מ שתוצג ראשית בצבע, עלי לפצל את אובייקט התמונה לגווני r, g, b ולכרוך אותם מחדש.

ובמצב אפור, של matplotlib של imshow"מ להציגה בגווני רמות אפור, כפי שראינו בהרצאה, מציגים עם [2, :, :]. במטריצת התמונה.



ד) את אלג' Canny edge detector ניתן כמובן להריץ על תמונה בגווני רמות אפור **בלבד**, ולכן נריץ אותו על התמונה השמאלית, האפורה.

הפרמטרים המשפיעים על טיב תוצאות האלגוריתם התמונה הם בעיקר שני ה thresholds של שלב ה Hysteresis Thresholding. פרמטרים אלה קובעים את סף הרגישות עבור הקצוות/ קווי המתאר אותם אנחנו רוצים למצוא ע"י האלג', וניתן לראות בתמונות הבאות את תוצאות ה"משחק" בפרמטרים אלו.



Threshold 1 – 50  
Threshold 2 - 200



Threshold 1 – 20  
Threshold 2 - 30

Threshold 1 – 300  
Threshold 2 - 500

כעת ברור כי, סף גבוה מאפשר לזהות פיקסלים חזקים ואילו סף נמוך מאפשר לזהות פיקסלים לא רלוונטיים. אם נגדיר שני ספים נמוכים, נקבך תמונה אשר מוצפת בקווי מתאר ולכן קשה מאוד לזהות את הפרטים בתמונה, תוצאה דומה נקבל גם עבור שני ספים גבוהים כאשר יותר מדי קווי מתאר יסווגו כלא רלוונטיים ויימחקו, וכך נקבל תמונה ובה קווי מתאר לא רציפים ומידע אובד.


לכן, ודאי שמתוך 3 התמונות עליהן הפעלנו את האלגוריתם עם פרמטרים שונים, עבור  $\text{sf} = 1$  ו- $\text{sf} = 50$  שני = 200, נתונים מאוזנים המאפשרים ריצה יעילה של האלג', נשיג את התוצאות הטובות ביותר.

כעת נציג את התוצאות המתקבלות מאופרטור סובל:




נראה שהתוצאות המתקבלות מאופרטור סובל הינן מאופיינות בקווי מתאר עבים וגסים יותר, כל פיקסל עובר פילטר אנכי ואופקי, ולכן החישוב אינו "יקר" ויעל. אולם, מסיבה זו ההערכה של הגרדיאנט הי די גסה, מה שמוביל לקווי מתאר מרוחים מעט.

(ה) נשים לב לתמונה המקורית ולתוצאות עבור שני הסטים השונים של הפרמטרים.



```
cornerHarris(gray,2,3,0.04)
```




```
cornerHarris(gray,2,3,0.9)
```

עם threshold אופטימלי(ע"פ רוב, מאוד תלוי בתמונה) של  $\text{img}[dst > 0.01 * dst.max()]$

ולכן קל לראות שעבור הנתונים המיוצגים בתמונה השמאלית, מושגת התוצאה הטובה יותר- כאשר המשתנה החופשי של האלג' k הינו עדין- קטן, מאפשר לזהות את הפינות ולסמןן באדום.

## שאלה 2


(א) השתמשתי בפונק' הנתונה `plot_cov_ellipse` עם הנתונים בשאלה, ודגמתי 10 דגימות רנדומליות נורמליות ע"י `multivariate_normal`, עם המטריצה הקווריאנס והממוצע הנתונות.




(ב) את הדגימות שמרתי למערך `a`. כעת ע"פ הפונקציות המובנות של `numpy` עבור `mean` ו `cov` ניתן לשערך, לשחזר את נתוני ה `mean` וה `cov` המקוריים (נשמרו תחת `new_mean`, `new_cov`). משחק קצר עם מספר הדגימות מבהיר כי זהו הפרמטר בו תלויה רמת הדיוק של השיערוך. כעת, נחשב את ההפרשים המנורמלים בין ה `mean` וה `cov` המקוריים והמשוערים, ונציג את המרחק בין הערכים המשוערים שסכום ההפרשים המרובעים.

```
Estimated mean =
[-0.76778452  1.21023291]
Estimated cov =
[[1.22721191  0.59969117]
 [0.59969117  2.73181863]]


cov diff = 1.5098712595146906
mean dif = 0.823198689975034
Match rate is =
2.95736730348509
```



(ג) הרעיון הוא ליצור גריד ע"פ ההמלצה בשאלה ובתוכו לדגום. נציג את הייצוג של כל תמונת התפלגות (מקורית ומשוערת) וההפרש המנורמל של פונקציית ההתפלגות שלהם (pdf) בתמונה יהווה את ההבדל בין ההסתברויות.




משוער




מקור

## הפרש



(ד) כפי שהערתי בסעיף ב', הנתון המשפיע ביותר על מידת ההתאמה בין השיערוך לנתוני המקור הוא מס' הדגימות. נשים לב בגרף המתואר מטה, כבר החל מ-1800 דגימות לערך ומעלה, רמת השיפור היא זניחה והתוצאה טובה מספיק. כפי שרצינו, בפלט המודפס ניתן לראות שככל שמסך הדגימות עולה, ההבדל יורד. הנתונים מושגים ע"י ביצוע דגימות ברמה העולה בכל איטרציה, עד ל-10000.

```
sampels: 10,      diff: 2.7087779144957373  
sampels: 2000,   diff: 0.015441767841772765  
sampels: 10000,  diff: 0.0025343026586705734
```



### שאלה 3

א) מימשתי פירמידה לפלסיאנית עבור התמונה של ג'ורדן, ב6 רמות. תחילה כמובן בונים פירמידה גאוסיינית, ובאמצעותה לאחר מכן בונים את הלפלסיאנית.

Below- Upper level Gaussian Pyramid

Level 5 of Laplacian Pyramid



Level 4 of Laplacian Pyramid



Level 3 of Laplacian Pyramid




Level 2 of Laplacian Pyramid



Level 1 of Laplacian Pyramid



Original image





(ב) נבצע את התהליך מסעיף א עבור שתי התמונות, ובסופו ונאחד בכל רמה את התמונות המתאימות מהפירמידות. בשלב האחרון, הreconstruct נמזג ביניהם באופן מותאם ומשתלב, לקבל תמונה ממוזגת, ולא משודכת.

משחק עם ערכי הרמות יראה שעבור  $2/3$  רמות מיזוג התמונות דומה יותר להדבקה/ שידוך של שני גזרי התמונות, וזו תוצאה לא מספקת. ואילו עבור  $5/6$  רמות ויותר, מתקיים מעין ניקוי רעשין מהאובייקטים המרכזיים עצמם, טשטוש והמיזוג גם כן לא מספק. עבור 4 רמות מושגת התוצאה האופטימלית, כפי שניתן לראות:

Image b



Image a



Mix-reconstruct



Mix

